

Spectral Clustering

1 Introducere

Scopul acestui proiect este implementarea completă a metodei de *spectral clustering* pentru grafuri neorientate, utilizând exclusiv metode numerice clasice pentru calculul valorilor și vectorilor proprii. Problema este abordată prin analiza spectrală a matricei Laplacian a grafului și aplicarea unor algoritmi numerici precum transformările Householder, iterația QR implicită cu deplasare Wilkinson.

2 Modelarea matematică a grafului

Considerăm un graf neorientat

$$G = (V, E), \quad |V| = n,$$

unde $V = \{1, 2, \dots, n\}$ este mulțimea nodurilor, iar E este mulțimea muchiilor.

Graful este reprezentat prin matricea de adiacență:

$$A = (a_{ij})_{i,j=1}^n, \quad a_{ij} = \begin{cases} 1, & (i, j) \in E, \\ 0, & \text{altfel.} \end{cases}$$

Se definește matricea de grad:

$$D = \text{diag}(d_1, d_2, \dots, d_n), \quad d_i = \sum_{j=1}^n a_{ij}.$$

Laplacianul grafului este:

$$L = D - A.$$

3 Problema spectral clustering

Matricea Laplacian L este simetrică și semidefinit pozitivă, având valori proprii reale:

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

Vectorii proprii corespunzători valorilor proprii mici conțin informații esențiale despre structura de comunități a grafului. În particular:

- vectorul propriu asociat lui λ_2 (vectorul lui Fiedler) permite separarea în două clustere;
- vectorii proprii asociați lui λ_2 și λ_3 permit separarea în trei clustere.

4 Reducerea la problemă de valori proprii

Problema se reduce la rezolvarea ecuației:

$$Lx = \lambda x.$$

Pentru eficiență numerică, se aplică următorii pași:

1. tridiagonalizarea matricei L ;
2. aplicarea algoritmului QR implicit cu deplasare;
3. extragerea valorilor proprii;
4. calculul vectorilor proprii corespunzători.

5 Tridiagonalizarea prin transformări Householder

Pentru orice matrice simetrică $L \in \mathbb{R}^{n \times n}$ există o matrice ortogonală Q astfel încât:

$$Q^T L Q = T,$$

unde T este o matrice tridiagonală simetrică.

Această transformare se realizează printr-o succesiune de reflectori Householder:

$$H_k = I - \beta_k u_k u_k^T.$$

Fiecare reflector anulează elementele subdiagonale dintr-o coloană, păstrând simetria matricei. La final se obține:

$$T = Q^T L Q, \quad Q = H_1 H_2 \dots H_{n-2}.$$

6 Algoritmul QR implicit cu deplasare Wilkinson

Pentru matricea tridiagonală T , se aplică iterația QR implicită:

$$T - \mu I = QR,$$

$$T_{\text{nou}} = RQ + \mu I.$$

Deplasarea Wilkinson este definită prin:

$$\mu = f_n - \frac{g_{n-1}^2}{\alpha + \text{sign}(\alpha) \sqrt{\alpha^2 + g_{n-1}^2}}, \quad \alpha = \frac{f_{n-1} - f_n}{2}.$$

Această alegere accelerează convergența și păstrează structura tridiagonală.

Convergența este atinsă atunci când:

$$|g_i| \rightarrow 0,$$

iar elementele diagonale converg către valorile proprii ale lui L .

7 Calculul vectorilor proprii

Pentru o valoare proprie λ , vectorul propriu este determinat prin rezolvarea unui sistem liniar:

$$(L - \lambda I)v_{k+1} = v_k,$$

urmată de normalizare:

$$v_{k+1} \leftarrow \frac{v_{k+1}}{\|v_{k+1}\|}.$$

Această metodă converge rapid atunci când λ este cunoscut cu precizie suficientă.

8 Strategii de clustering

8.1 Separare în două clustere

Folosind vectorul propriu v_2 , se definește:

$$\text{cluster}(i) = \begin{cases} 0, & v_2(i) < 0, \\ 1, & v_2(i) \geq 0. \end{cases}$$

Această separare corespunde unei tăieturi spectrale minimale.

8.2 Separare în trei clustere

Folosind vectorii proprii v_2 și v_3 , nodurile sunt împărțite în funcție de semnele componentelor:

$$\text{cluster}(i) = \begin{cases} 0, & v_2(i) \geq 0 \wedge v_3(i) \leq 0, \\ 1, & v_2(i) < 0 \wedge v_3(i) \geq 0, \\ 2, & \text{altfel.} \end{cases}$$

9 Validare

Rezultatele obținute sunt comparate cu implementarea standard `SpectralClustering` din `scikit-learn`, folosind indicele *Adjusted Rand Index (ARI)* pentru evaluarea calității clusterizării.

10 Concluzii

Proiectul demonstrează implementarea completă a metodei de spectral clustering, folosind exclusiv algoritmi numerici clasici pentru calculul spectrului Laplacianului. Rezultatele obținute sunt consistente cu metodele standard și validează corectitudinea abordării numerice.